Практическая ценность проекта

Система извлечения структурированной информации из неструктурированных текстов с использованием LLM

1. Проблема

В современных бизнес-процессах огромные объемы ценной информации хранятся в неструктурированном виде: тексты договоров, резюме соискателей, медицинские выписки, новостные ленты и отчеты. Ручное извлечение ключевых данных (дат, сумм, имен, условий) из таких документов является трудоемким и медленным процессом, подверженным человеческим ошибкам. Традиционные методы на основе регулярных выражений (RegEx) плохо справляются с вариативностью формулировок и требуют постоянной ручной доработки правил.

2. Предлагаемое решение

Разрабатываемая программная система использует большие языковые модели (LLM) для семантического понимания текста и автоматического извлечения заданных сущностей. Архитектура решения включает:

- **LLM API / локальная LLM** как основной движок понимания естественного языка.
- **Pydantic** для строгой валидации и гарантированного структурирования ответа модели в формат JSON.
- **FastAPI** для предоставления удобного и масштабируемого REST API.
- **PostgreSQL** для надежного хранения извлеченных данных и метаданных.
- **Docker** для обеспечения воспроизводимости и простоты развертывания.

3. Целевые сценарии использования (Use Cases)

- **HR и рекрутинг:** автоматический парсинг резюме с извлечением ФИО, контактов, списка навыков и опыта работы для загрузки в ATS-системы.
- **Юриспруденция:** извлечение сторон договора, сроков действия, штрафных санкций и сумм из текстов контрактов для формирования реестра обязательств.
- **Финансовый мониторинг:** анализ новостных потоков и отчетов компаний для автоматического выделения финансовых показателей и ключевых событий.

4. Ожидаемый практический эффект

- **Сокращение времени обработки:** уменьшение времени анализа одного документа с нескольких минут (ручной труд) до нескольких секунд.
- **Снижение операционных затрат:** высвобождение ресурсов сотрудников от рутинной работы для решения более сложных аналитических задач.

- **Масштабируемость и интеграция:** благодаря реализации в виде API (FastAPI) и контейнеризации (Docker), система легко встраивается в существующие корпоративные информационные системы (CRM, ERP).
- **Измеряемое качество:** разработка собственной методики оценки позволяет количественно измерять точность (Precision), полноту (Recall) и F1-меру извлечения, гарантируя контроль качества.

5. Заключение

Проект выходит за рамки академического исследования. Он представляет собой законченный, готовый к промышленному использованию прототип, который решает реальную бизнес-проблему трансформации неструктурированных данных в ценный структурированный актив, используя передовые возможности генеративного ИИ.